

Proyecto 2: PageRank sobre la red Wiki-Vote

Sebastián Blanco, Fernando Pavez, Vicente Pardo Silva

Curso: Algebra Lineal Avanzada y Modelamiento – IMT2230

Profesor: Felipe Urrutia – Ayudante: Luis Castillo

Link al repositorio: **LINK**

Introducción

En este proyecto aplicamos el algoritmo PageRank a la red de votaciones para elegir administradores de Wikipedia. En esta red los nodos representan usuarios de Wikipedia y una arista dirigida $i \rightarrow j$ indica que el usuario i votó por el usuario j en algún proceso de Request for adminship (RfA). La dump completa, de la cual se extrajo la red, reúne todas las elecciones de administradores de Wikipedia desde su creación hasta enero de 2008, con un total de 2.794 elecciones, 103.663 votos y 7.066 usuarios involucrados (ya sea votando o siendo votados). Aproximadamente la mitad de los votos provienen de administradores ya existentes, y la otra mitad, de usuarios comunes. La red que se construye a partir de estos datos tiene $n = 7.115$ nodos y $m = 103.689$ aristas, con un diámetro de 7, un 90-percentile effective diameter de 3,8 y un coeficiente de clustering promedio de 0,1409, lo que da cuenta de una red dirigida, dispersa (densidad aproximadamente 0,002) pero con una componente gigante bien conectada (7.066 nodos en la WCC más grande, es decir, el 99,3% del total).

1. Descripción de la red y estadísticas básicas

La red se descargó directamente desde **SNAP** y se cargó como `nx.DiGraph`. La tabla resume las estadísticas básicas:

Métrica	Valor
Cantidad de aristas	103.689
Cantidad de nodos	7.115
Grado de entrada medio	14,5733
Grado de salida medio	14,5733
Nodo de mayor grado de entrada	4037 (con 457 votos)
Cantidad de nodos colgantes	1.005
Densidad de la red	0,002049

La densidad cercana a cero indica que la mayoría de los pares de nodos no están conectados entre sí, es decir, la red es muy dispersa.

2. Pregunta e hipótesis inicial

Pregunta: ¿Qué usuarios de Wikipedia son los más influyentes dentro de la red de votaciones de adminship?

Hipótesis: mientras más importante es la persona que vota, más peso tiene su voto. Como consecuencia, esperamos que los usuarios con mayor PageRank coincidan con los de mayor grado de entrada.

3. Análisis exploratorio

3.1. Distribución de grado

La figura muestra la distribución de los grados de entrada y de salida de los 7.115 nodos de la red.




Figura 1: Distribución de grado de entrada y de salida. La cola pesada en ambos casos es característica de redes libres de escala.

Ambas distribuciones presentan una fuerte concentración cerca de cero con una cola larga hacia la derecha.

3.2. Nodos colgantes

Se identificaron **1.005 nodos colgantes** (grado de salida igual a cero), representando un 14,1% de la red.

Los 10 nodos con mayor grado de entrada son: 4037 (457), 15 (361), 2398 (340), 2625 (331), 1297 (309), 2565 (274), 762 (272), 2328 (266), 5254 (265) y 3352 (264). Los 10 con mayor grado de salida son: 2565 (893), 766 (773), 11 (743), 457 (732), 2688 (618), 1166 (599), 1549 (587), 1151 (472), 1374 (462) y 1133 (399). Se aprecia que el nodo 2565 aparece

en ambos rankings, lo que sugiere un usuario con alta actividad tanto recibiendo como votando.

3.3. Conexidad

`Nx.is_strongly_connected` devuelve `False` y se identificaron **5.816 componentes fuertemente conexas**. Esto significa que la red está formada por múltiples subconjuntos que no son alcanzables entre sí mediante caminos dirigidos. Sin embargo, esto no impide aplicar PageRank, ya que la Matriz de Google introduce una probabilidad positiva entre cualquier par de nodos a través del término $(1 - \alpha)1\frac{1^T}{n}$, lo que la hace irreducible y aperiódica.

4. Construcción de la Matriz de Google

4.1. Matriz de hipervínculos H

$H \in \mathbb{R}^{n \times n}$ se define columna a columna, si el nodo j no es colgante y i es uno de sus «out»(j) destinatarios, entonces $H_{ij} = 1/\text{out}(j)$, y 0 en caso contrario. Cada columna de H suma 1 cuando el nodo fuente no es colgante, ya que cada una de las $\text{out}(j)$ conexiones aporta el mismo peso y, al factorizar, el resultado es 1. Las columnas asociadas a nodos colgantes quedan completamente en cero.

En la implementación se construyó H como $H = (D^{-1}A)^\top$, donde A es la matriz de adyacencia del grafo y D es la matriz diagonal con los grados de salida, equivalente a `H = (diag_matriz @ adj_matrix).T` en el código, usando representación dispersa con `scipy.sparse`.

4.2. Matriz columna-estocástica S

Las columnas cero de H (correspondientes a los 1.005 nodos colgantes) se reparan reemplazándolas por el vector uniforme $1/n$, es decir, $S = H + a\frac{1^T}{n}$ donde $a_j = 1$ si el nodo j es colgante y 0 en caso contrario. Tras esta reparación se verificó que `S.sum(axis=0) == 1` para todas las columnas.

4.3. Matriz de Google G

$G = \alpha S + (1 - \alpha)1\frac{1^T}{n}$ con $\alpha = 0,85$. El valor de $\alpha = 0,85$ representa que el 85% de las veces el caminante sigue un enlace real y el 15% restante salta uniformemente a cualquier nodo. La suma del segundo término sobre todas las entradas de una columna es $(1 - \alpha)$, lo que sumado a α da 1 por columna. Como $\alpha > 0$, $1 - \alpha > 0$ y todas las entradas de S son no-negativas, todas las entradas de G son estrictamente positivas, lo que se confirma al inspeccionar la matriz construida de tamaño 7.115×7.115 , donde las entradas típicas son del orden de $2,11 \times 10^{-5}$.

5. Cálculo del PageRank

Al implementar el cálculo del PageRank, El algoritmo convergió en **29 iteraciones** con error final $9,08 \times 10^{-11}$.




Figura 2: Convergencia de la iteración de potencias, el error decae geoméricamente.

5.1. Top-20 PageRank

Rank	Nodo	PageRank	Grado entrada	Grado salida
1	4037	0,004607	457	15
2	15	0,003680	361	50
3	6634	0,003587	203	3
4	2625	0,003284	331	0
5	2398	0,002609	340	62
6	2470	0,002524	149	0
7	2237	0,002497	181	241
8	4191	0,002268	259	20
9	7553	0,002170	190	0
10	5254	0,002150	265	33
11	2328	0,002039	266	215
12	1186	0,002036	193	0
13	1297	0,001946	309	76
14	4335	0,001937	228	32
15	7620	0,001932	208	0
16	5412	0,001919	219	0
17	7632	0,001908	178	0

Rank	Nodo	PageRank	Grado entrada	Grado salida
18	4875	0,001874	181	0
19	6946	0,001808	117	68
20	3352	0,001784	264	273

6. PageRank vs. grado de entrada

La figura siguiente muestra el scatter de grado de entrada vs. PageRank para los 7.115 nodos, con los 10 de mayor PageRank destacados.




Figura 3: Grado de entrada vs. PageRank. Los puntos rojos corresponden al top-10 por PageRank.

La correlación de Pearson entre ambas medidas es **0,9223**, lo que confirma una relación fuerte.

6.1. Casos donde PageRank y grado de entrada difieren

Un caso llamativo es el **nodo 6634**, que aparece en el top 3 de PageRank con valor 0,003587 pese a tener sólo 203 votos recibidos y grado de salida

3. Su alto PageRank no proviene de recibir muchos votos, sino de

recibirlos desde personas que a su vez tienen PageRank alto, por lo que esos pocos votos pesan más que muchos votos emitidos por personas influyentes pero de bajo PageRank. En el otro extremo, el **nodo 2565** tiene el mayor grado de salida de la red (893 votos emitidos) y un alto grado de entrada (274), pero su PageRank es apenas 0,001551 al emitir tantos votos, reparte su importancia entre muchos destinatarios.

7. Interpretación de resultados

7.1. Subgrafo de los nodos más influyentes

La figura muestra el subgrafo inducido por los 40 nodos de mayor PageRank, con los nodos escalados proporcionalmente a su valor de PageRank.




Figura 4: Subgrafo de los 40 nodos con mayor PageRank. El tamaño de cada nodo es proporcional a su PageRank.

Se aprecia que la mayoría de los nodos más influyentes están conectados entre sí, lo que es coherente con la lógica de que quienes reciben votos de otros nodos influyentes también quedan en un top alto.

8. Conclusiones y limitaciones

La hipótesis de que **mientras más importante es la persona que vota, más peso tiene su voto** se ve reflejada directamente en los resultados. La correlación de 0,92 con el grado de entrada confirma que recibir muchos votos es el factor dominante en esta red. Una limitación podría ser que, como el dataset Wiki-Vote no incluye atributos ni etiquetas para los nodos más allá de su identificador numérico, no es posible clasificarlos por grupo, comunidad u orientación. Esto impide responder si los usuarios de mayor PageRank pertenecen a una subcomunidad particular de Wikipedia o si están distribuidos de forma más general.

9. Bibliografía

- J. Leskovec, D. Huttenlocher, J. Kleinberg. *Signed Networks in Social Media*. CHI 2010.
- J. Leskovec, D. Huttenlocher, J. Kleinberg. *Predicting Positive and Negative Links in Online Social Networks*. WWW 2010.
- SNAP Datasets: Wikipedia vote network. snap.stanford.edu/data/wiki-Vote
- Recursos python. *Compresión y descompresión de archivos zip, gz y bz2*. recursospython.com
- Carazo, F. y Amat, J. *Métricas de Grafos y Redes*. cienciadedatos.net
- Stack Overflow. *Ignore divide by 0 warning in NumPy*. stackoverflow.com
- Cliburn, C. (2017). Sparse Matrices-Application: PageRank. people.duke.edu